# APRENDIZAJE AUTOMÁTICO

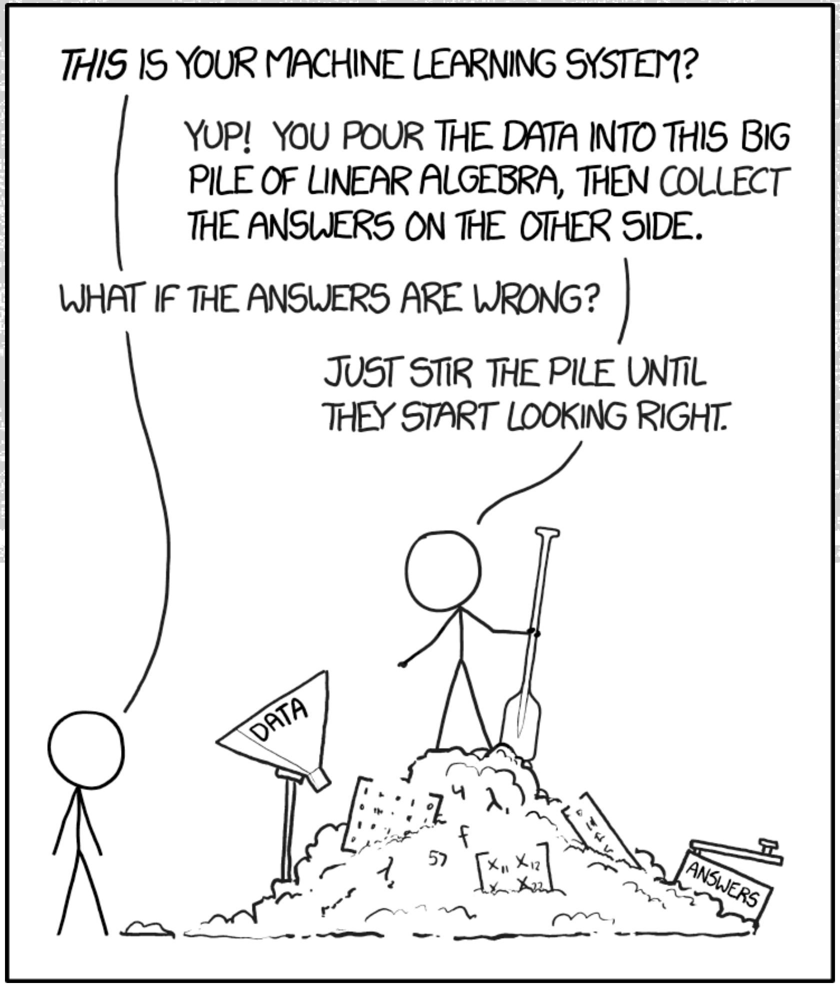

# AGENDA

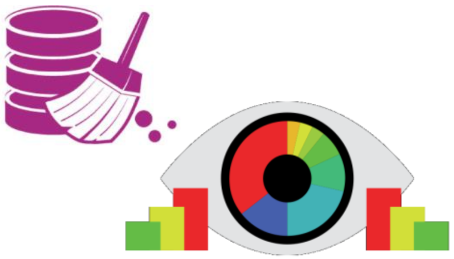

**Exploratory Data Analysis (EDA)**

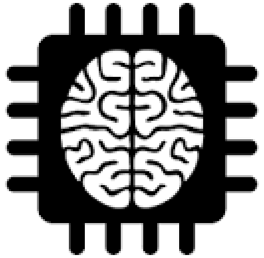

**Aprendizaje automático**

# Clase anterior

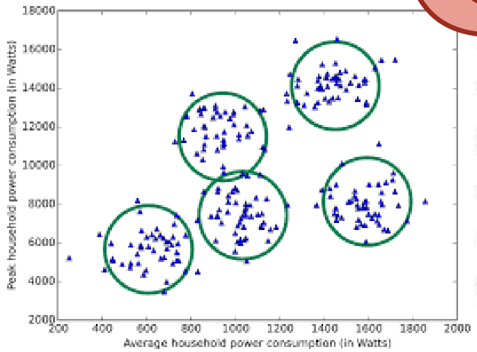

**Aprendizaje no supervisado**

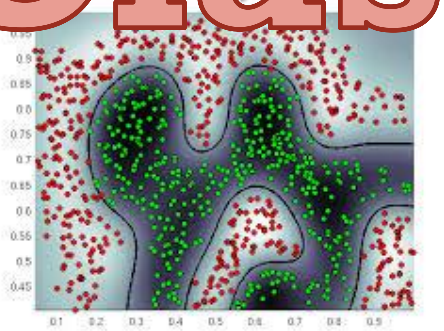

**Aprendizaje supervisado**

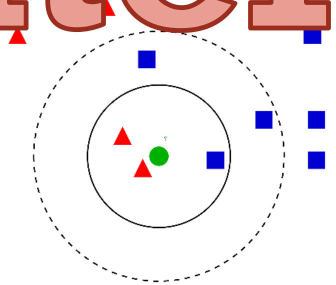

**KNN**

# AGENDA

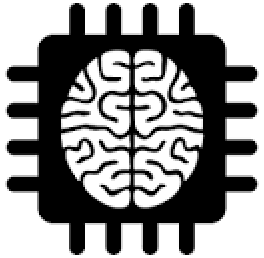

Aprendizaje automático

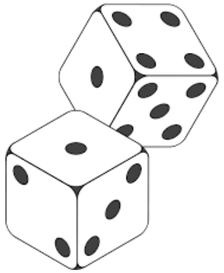

Probabilidad

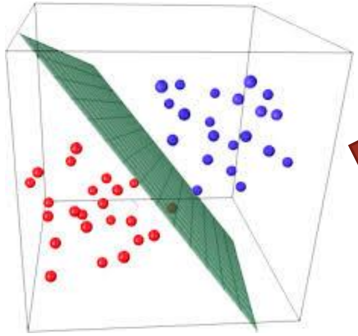

Clasificación

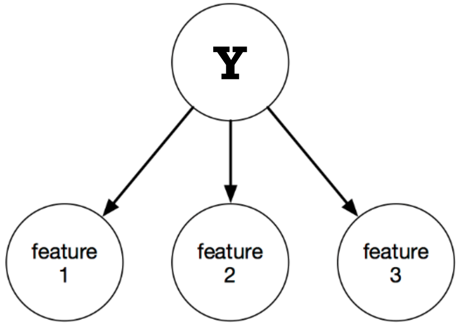


Naïve Bayes

Protocolos

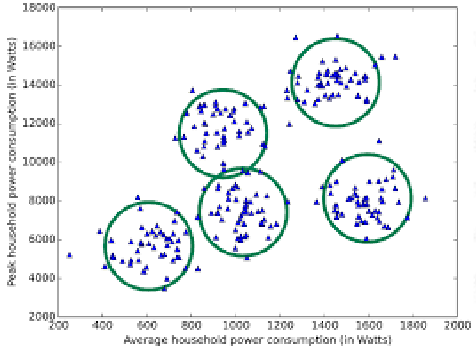


Aprendizaje no supervisado

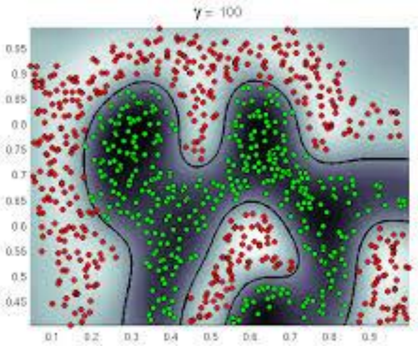


Aprendizaje supervisado

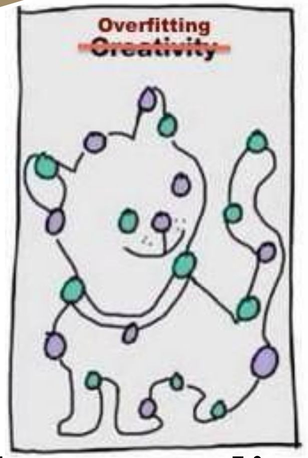


Sobre aprendizaje (Overfitting)

# OVERFITTING

# SESGO/ VARIANZA

- **Sesgo** (bias): que tan lejos está el modelo de la verdad
- **Varianza**: Qué tanto varían los datos de la predicción para una misma instancia

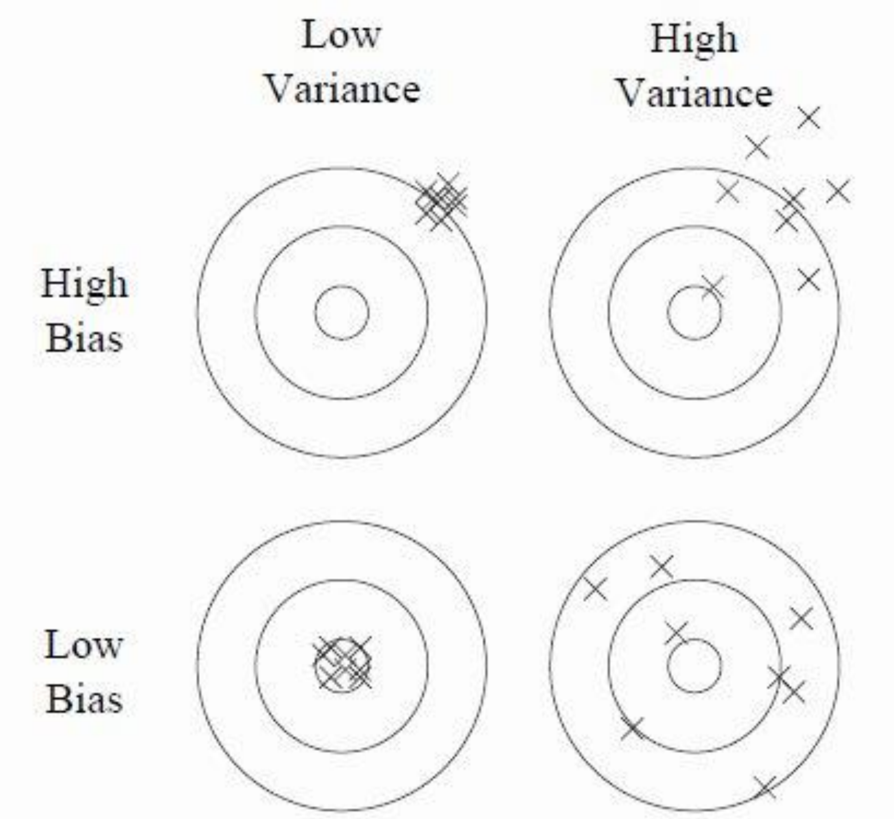


Domingo, 2012

# SESGO/ VARIANZA

- Ambos son fuente de error
- Se debe determinar un **compromiso** entre ambos tipos de error
- Parámetros de los modelos controlan la complejidad

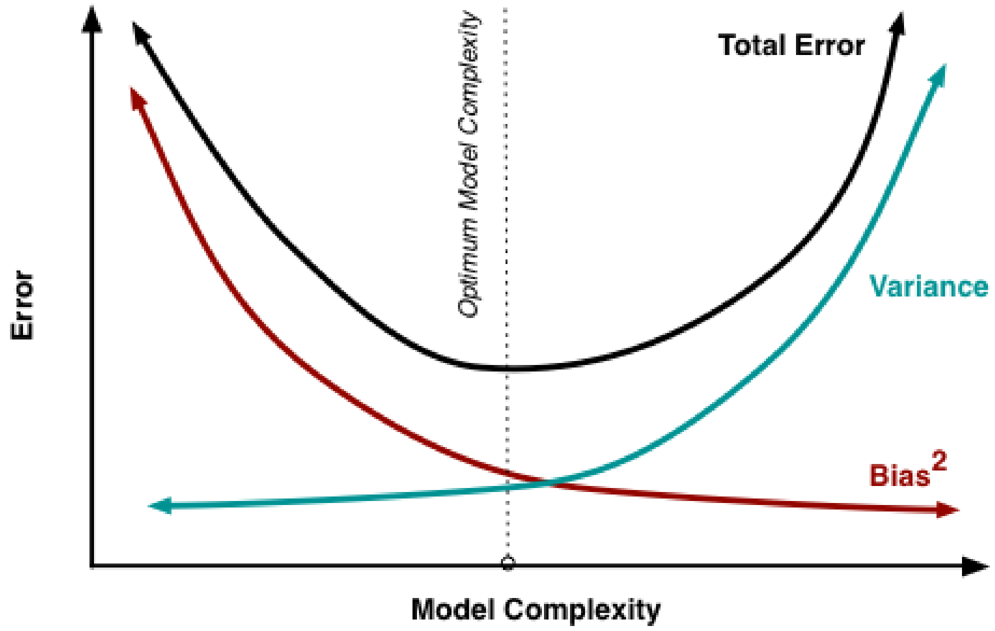


http://scott.fortmann-roe.com/docs/BiasVariance.html

# SOBRE APRENDIZAJE (OVERFITTING)

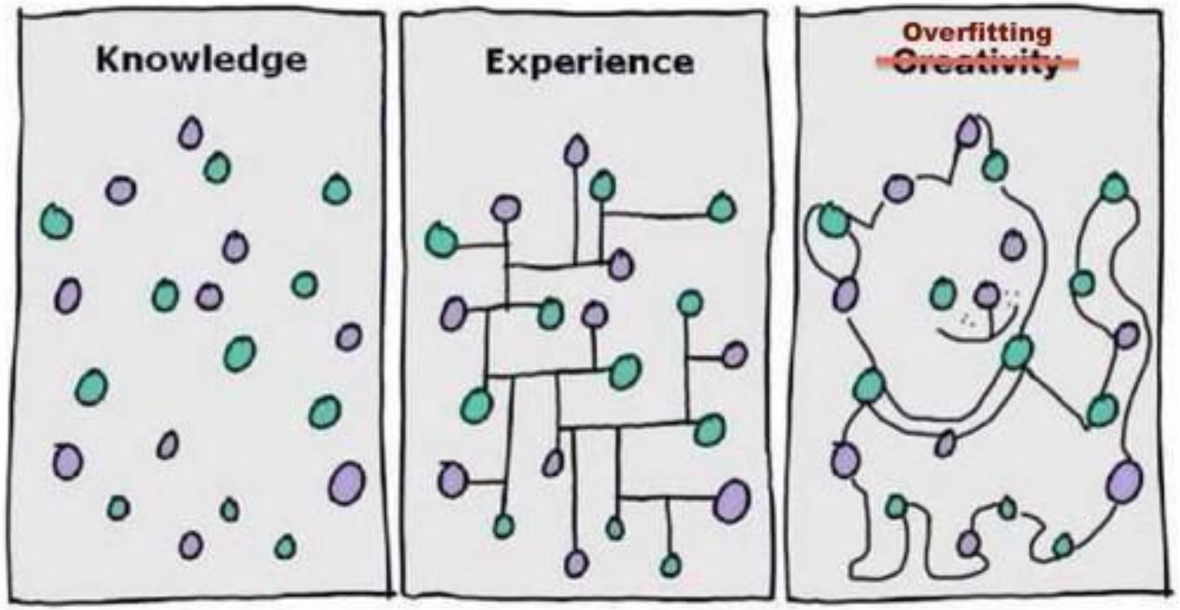


http://blog.algotrading101.com/design-theories/what-is-curve-fitting-overfitting-in-trading/

- **Sobre aprendizaje**: Los modelos aprenden a describir los errores aleatorios o el "ruido" del conjunto de entrenamiento.
- Ocurre cuando un modelo se vuelve excesivamente **complejo**

# SOBRE APRENDIZAJE (OVERFITTING)

**Regresión**

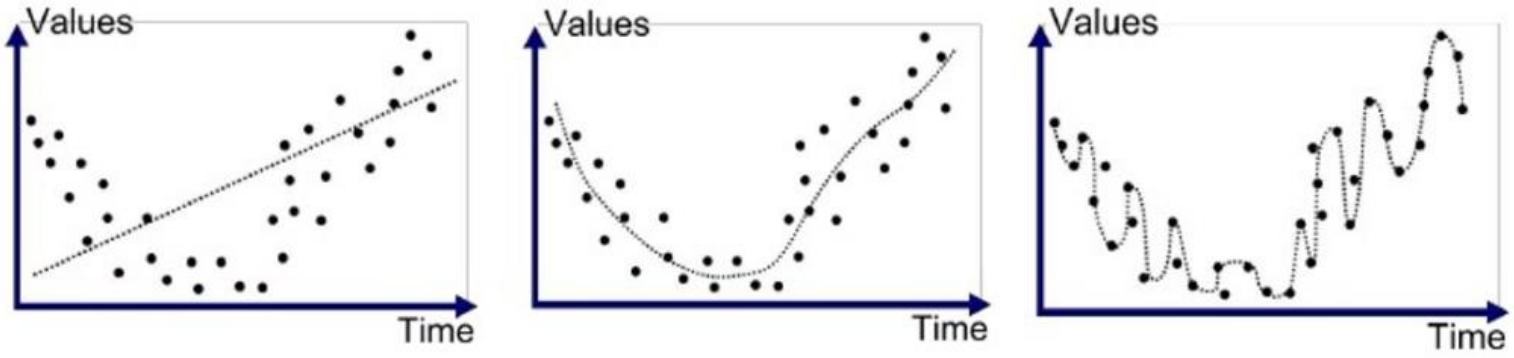


**Clasificación**

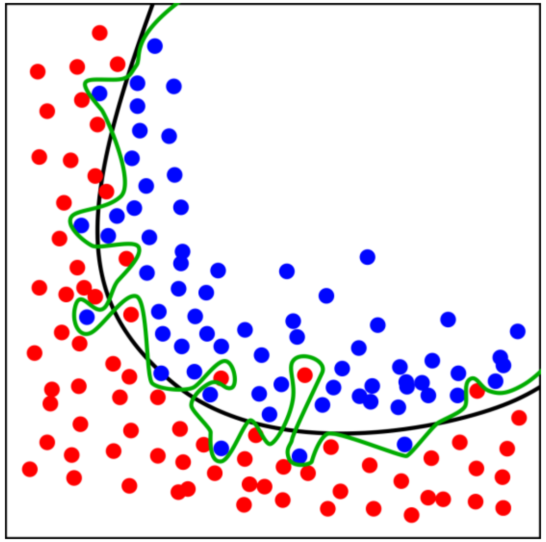

https://en.wikipedia.org/wiki/Overfitting

**¿Cómo es el sesgo y la varianza de estos modelos?**

- La **complejidad** de un modelo debe ajustarse de tal manera que permita la **generalización**, al utilizarse con datos que no haya conocido durante el proceso de entrenamiento

# SOBRE APRENDIZAJE (OVERFITTING)

- Los modelos tienden a ajustarse al conjunto de datos usado para su aprendizaje → el **error de entrenamiento** es un mal estimador
- Queremos encontrar la complejidad del modelo que nos permita minimizar el **error de test**

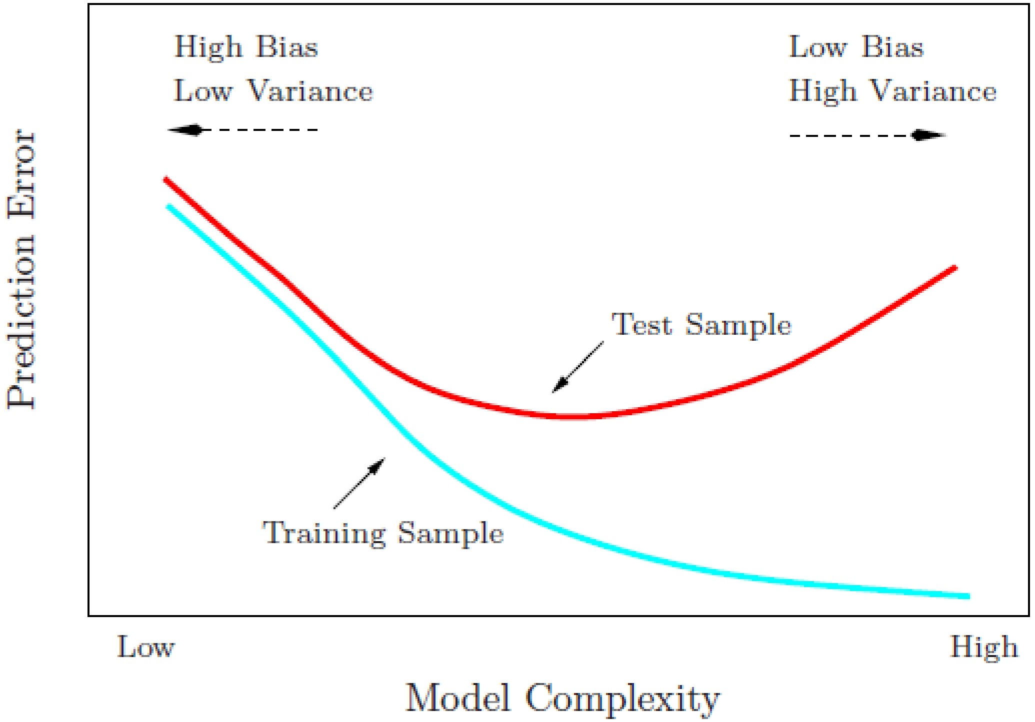


https://onlinecourses.science.psu.edu/stat857/node/160

# AGENDA

Aprendizaje automático

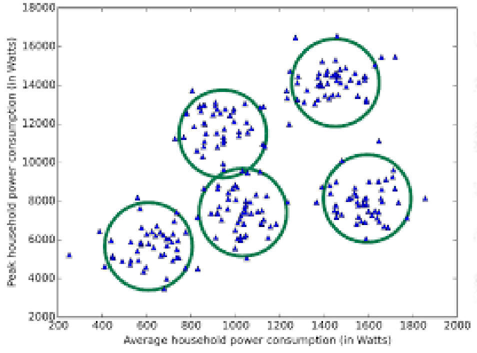


Aprendizaje no supervisado

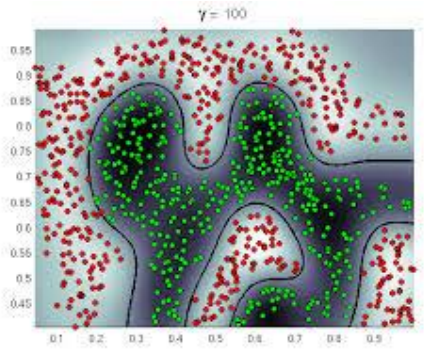


Aprendizaje supervisado

Protocolos

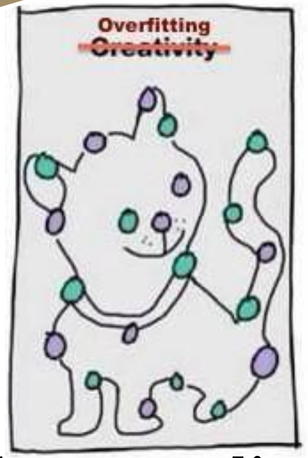


Sobre aprendizaje (Overfitting)

# PROTOCOLOS DE EVALUACIÓN

# PROTOCOLOS DE EVALUACIÓN

- Aplican para aprendizaje supervisado en general (tanto para clasificación como para regresión.
- Evaluar cual sería la capacidad de **generalización** del modelo a datos nuevos
- Diferenciar entre el **error de entrenamiento** y el **error de test.** Evitar el sesgo causado por la **subestimación del error** al evaluar con el mismo set de entrenamiento.
- Permitir establecer un compromiso entre sesgo y varianza, luchando contra el **sobre aprendizaje**, en busca de un modelo con buenas **capacidades predictivas**

# PROTOCOLOS DE EVALUACIÓN

- **Holdout**: particionar el conjunto de datos en 2:
  - **Conjunto de entrenamiento**: con el que se aprende el algoritmo de clasificación
  - **Conjunto de validación o test**: separa al comienzo del procedimiento y no se considera en el aprendizaje
  - **Aleatoriedad** del particionamiento
  - **Compromiso**: entre mas datos mejor el aprendizaje, entre mas datos mejor la evaluación
- **Repeated holdout**: repetir el procedimiento y agregar las métricas de evaluación

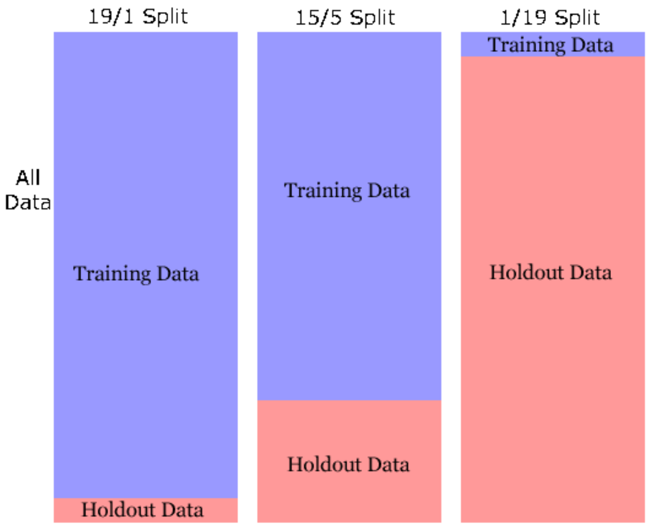


https://webdocs.cs.ualberta.ca/~aixplore/learning/DecisionTrees/InterArticle/6-DecisionTree.html

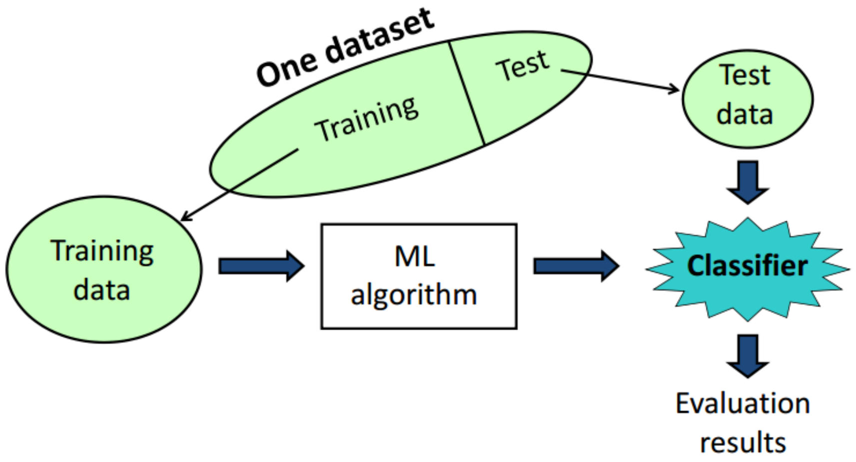


Ian Witten, Weka MOOC

# PROTOCOLOS DE EVALUACIÓN

- **K-fold cross-validation**:
  - Particionar el set de datos en K conjuntos disyuntos del mismo tamaño
  - K-1 partes se usan para entrenamiento, 1 parte se usa para el test
  - Se repite el proceso K veces
  - Se agregan las métricas de evaluación

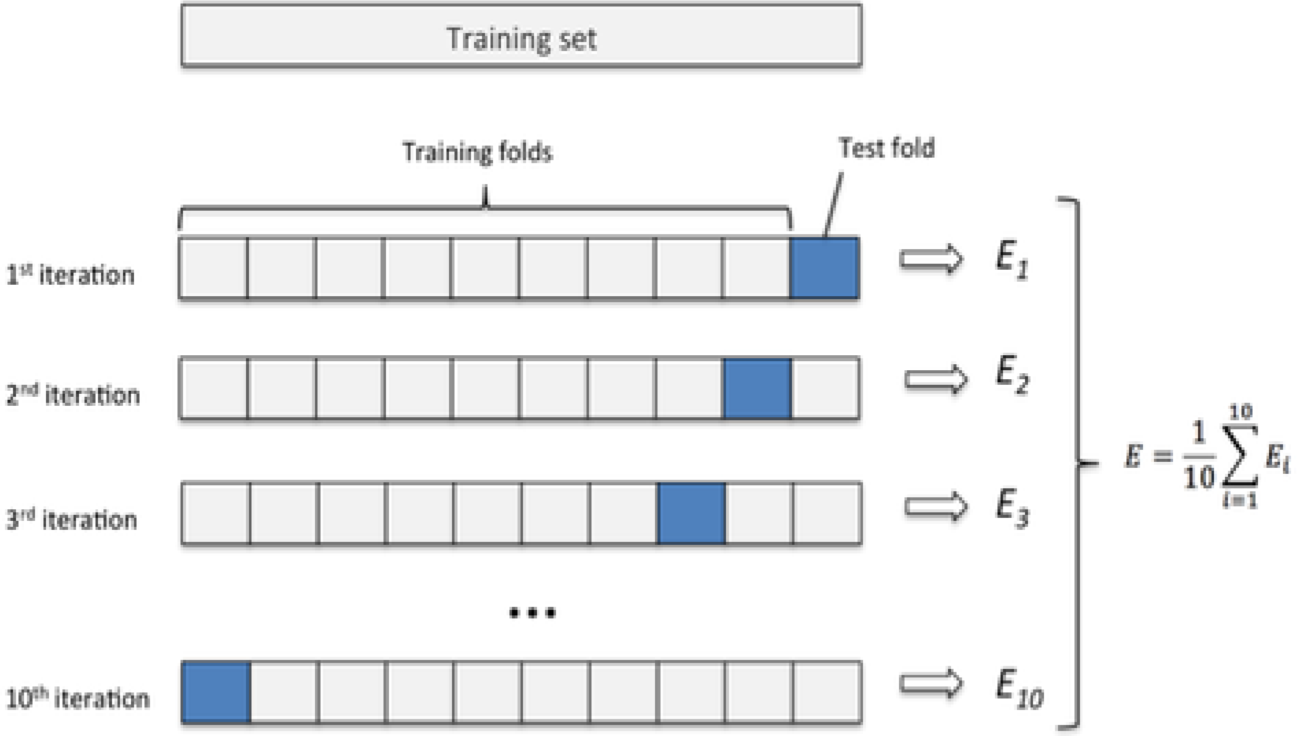


Sebastian Raschka, 2015

# PROTOCOLOS DE EVALUACIÓN

- **K-fold cross-validation,** **Escogencia del K**:
  - Permite balancear entre sesgo y varianza
  - **LOOCV** (Leave One Out Cross-Validation): partes de tamaño 1
  - Por defecto se estima que los mejores resultados se obtienen con un valor de K entre 5 y 10

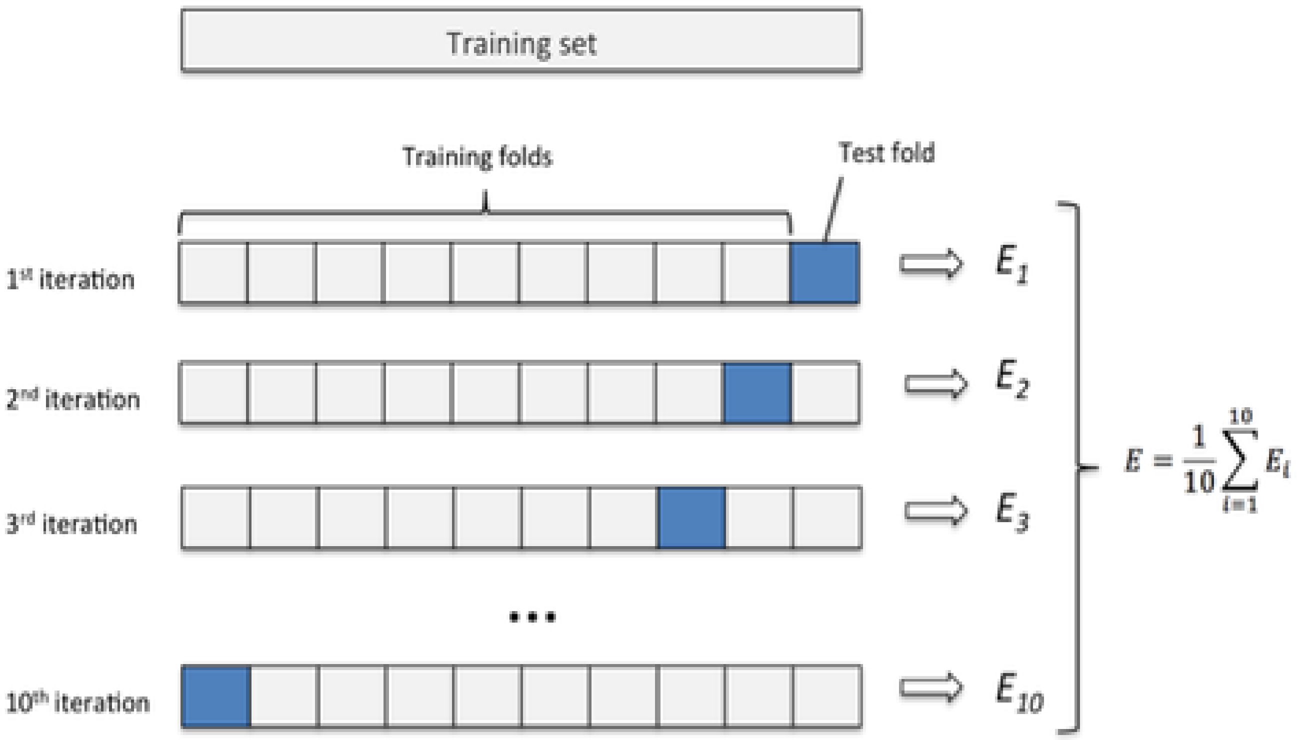


Sebastian Raschka, 2015

# PROTOCOLOS DE EVALUACIÓN

- **Bootstrapping**:
  - Consideración de varios conjuntos de entrenamiento/test utilizando muestreo con remplazo
  - Por lo general muestreos del mismo tamaño del conjunto original

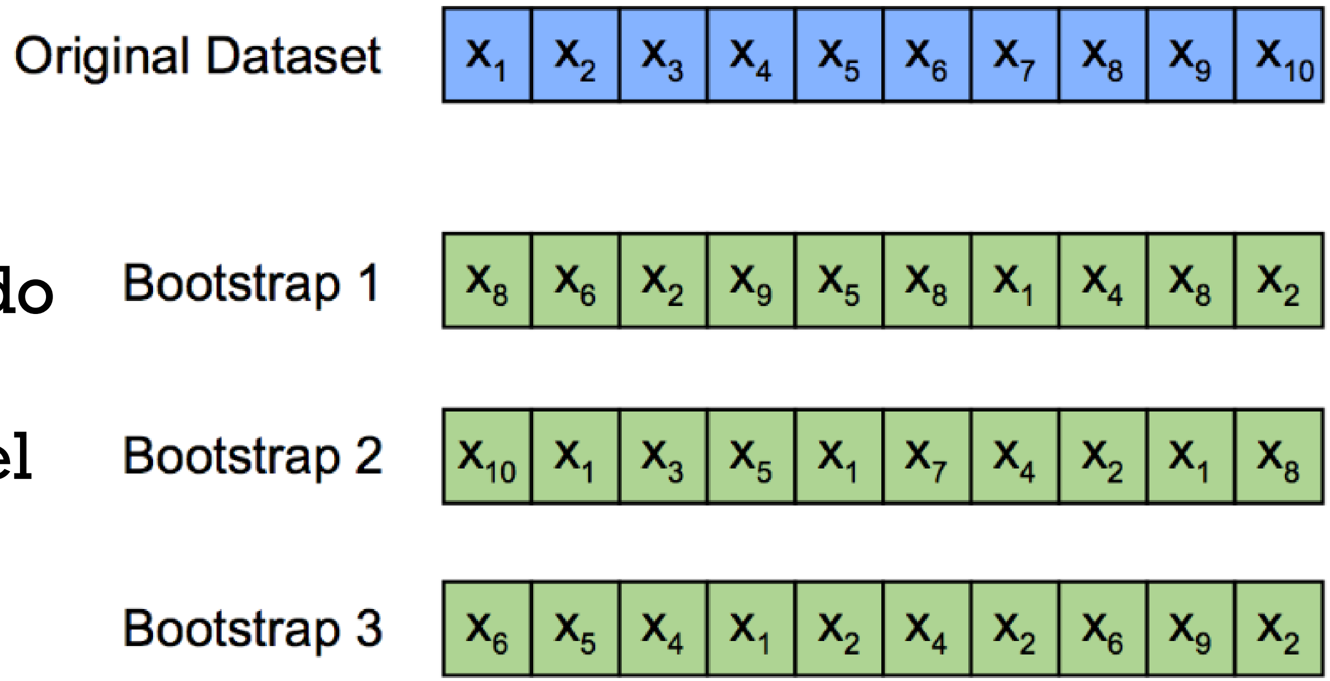


Sebastian Raschka, 2015

# TALLER DE CLASIFICACIÓN CON KNN

- Dataset: Iris
- Evaluar los diferentes protocolos y establecer un valor de K, así como un intervalo de confianza para la exactitud de la predicción.

# AGENDA

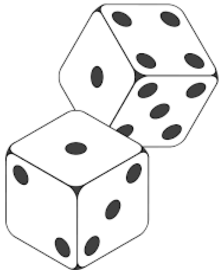

Probabilidad

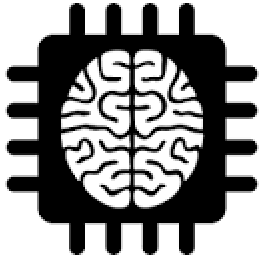

Aprendizaje
automático

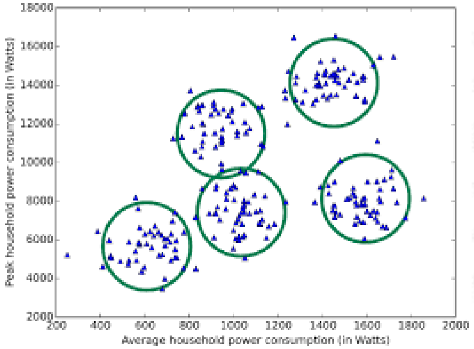


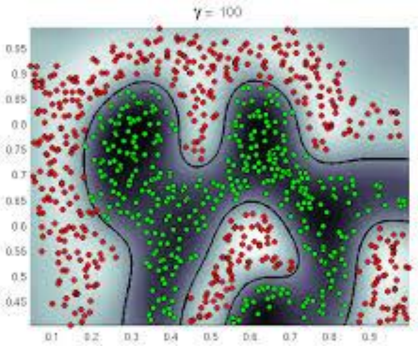


Aprendizaje
no supervisado

Aprendizaje
supervisado

Protocolos

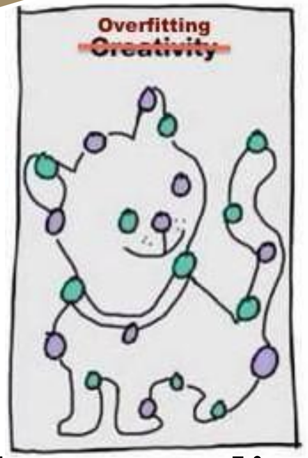


Sobre aprendizaje
(Overfitting)

# PROBABILIDADES

Socrative, ROOM = ICESI20191

# NAIVE BAYES: TALLER

Descarguen el taller de Excel y Word de Naive Bayes.

Desarrollen las partes 1 y 2 del taller, de repaso del calculo de probabilidades básicas y de entendimiento de la condicionalidad

# PROBABILIDADES

Marginalización: $p(X = x_i) = \sum_j p(x_i, y_j)$

Regla de producto: $p(X = x_i, Y = y_j) = p(Y = y_j | X = x_i) * p(X = x_i)$

$p(X = x_i, Y = y_j) = p(X = x_i | Y = y_j) * p(Y = y_j)$

Regla de Bayes: $p(Y = y_j | X = x_i) = \frac{p(X = x_i | Y = y_j) * p(Y = y_j)}{p(X = x_i)}$

Independencia: $p(Y = y_j | X = x_i) = p(Y = y_j)$

$p(X = x_i, Y = y_j) = p(X = x_i) * p(Y = y_j)$

# AGENDA

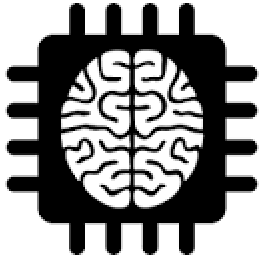

Aprendizaje automático

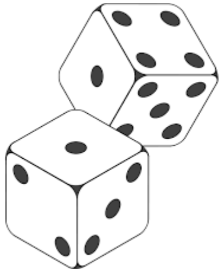

Probabilidad

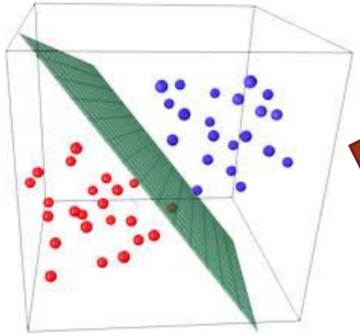

Clasificación

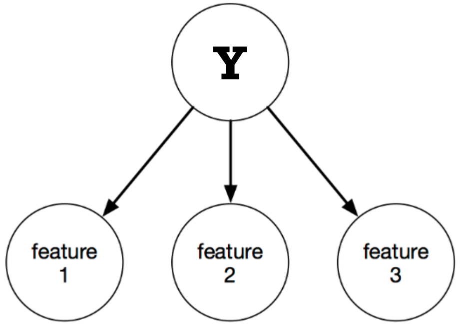


Naïve Bayes

Protocolos

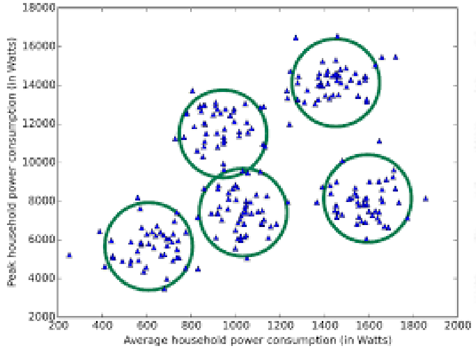


Aprendizaje no supervisado

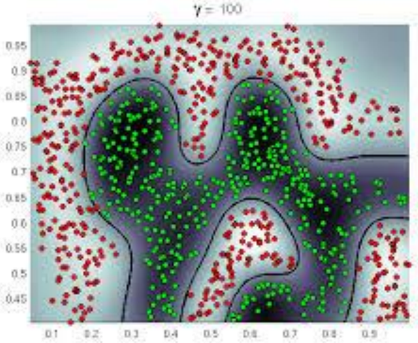


Aprendizaje supervisado

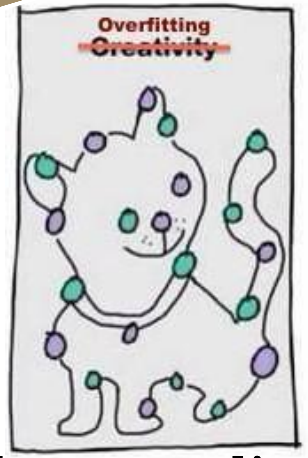


Sobre aprendizaje (Overfitting)

# NAÏVE BAYES

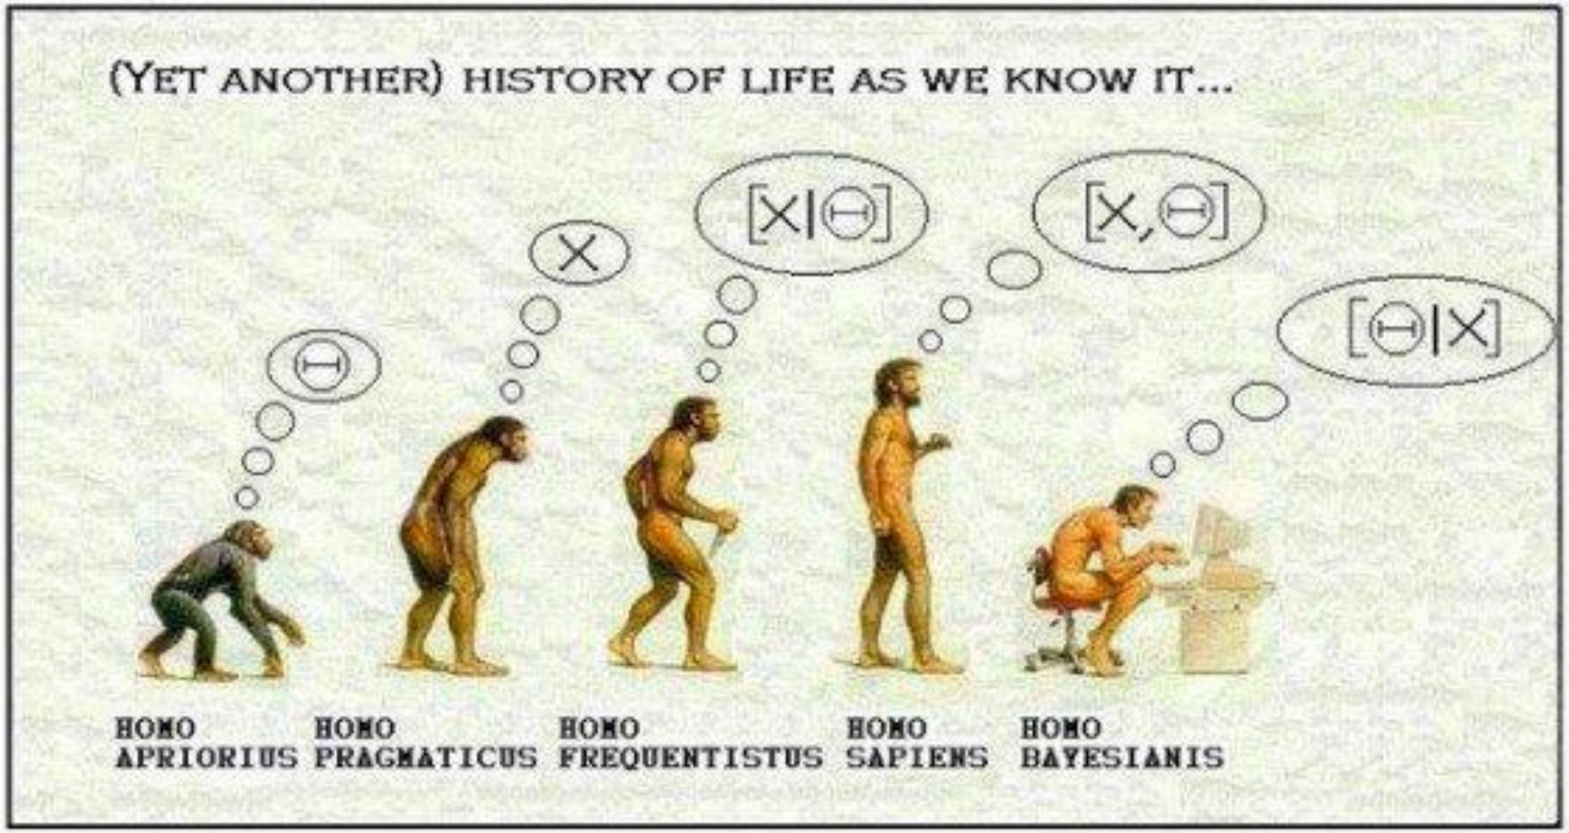
(YET ANOTHER) HISTORY OF LIFE AS WE KNOW IT...
[Θ]
[X]
[X|Θ]
[X,Θ]
[Θ|X]
HOMO APRIORIUS
HOMO PRAGMATICUS
HOMO FREQUENTISTUS
HOMO SAPIENS
HOMO BAYESIANIS

# CLASIFICADORES BAYESIANOS

- **Clasificadores bayesianos**: Asignar cada observación a la clase $j$ más probable, dados los valores observados de sus variables predictivas:

$$argmax_j \; p(Y = y_j | X = x_{observados})$$

- Si se conoce perfectamente las distribuciones de probabilidad, el clasificador resultante da la frontera de separación óptima en términos de error
- No siempre se tienen las probabilidades condicionales necesarias.
- **Naïve Bayes** propone una simplificación

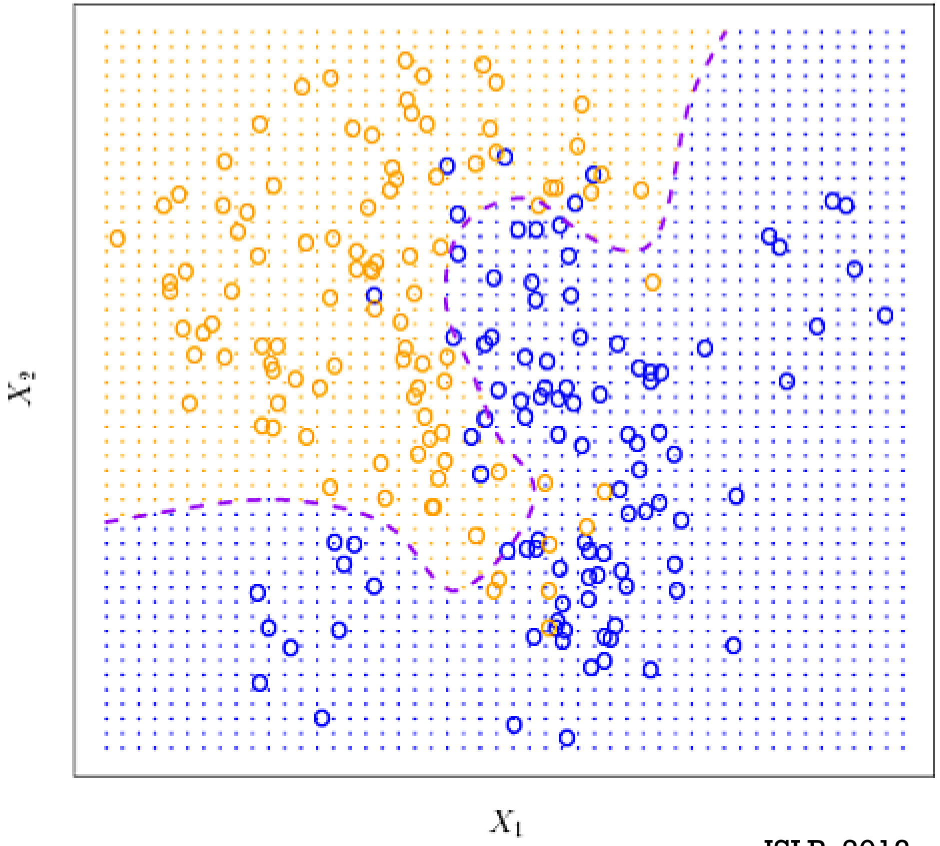


ISLR, 2013

# NAIVE BAYES

**Ejemplo**: Un banco quiere predecir si un cliente va a adquirir un CDT.

Creamos un clasificador Naïve Bayes a partir de los datos históricos para calcular las probabilidades posteriores para cada clase: subscribed=yes and subscribed=no.

{Single, Married, Divorced}

{Subscribed Yes, Subscribed No}

$$argmax_j \; p(\boxed{y_j}) \prod_{i-1}^{n} p(\boxed{x_i} | \boxed{y_j})$$

| Marital | Subscribed=yes |
|---|---|
| Single | 35% |
| Married | 53% |
| Divorced | 12% |

| Marital | Subscribed=no |
|---|---|
| Single | 28% |
| Married | 61% |
| Divorced | 11% |

| | |
|---|---|
| Subscribed=yes | 11% |

| | |
|---|---|
| Subscribed=no | 88% |

¿Debería el banco ofrecerle un CDT al cliente con la información siguiente?

Job=Management
Marital=Married
Education=Secondary
Default=no
Housing=yes
Loan=no
Contact=Cellular
Outcome=Success

Suponga que se disponen de las probabilidades condicionales para todas las variables predictivas (ya ilustradas para el estado civil "Marital")

# NAIVE BAYES

**Ejemplo**: Un banco quiere predecir si un cliente va a adquirir un CDT.

Creamos un clasificador Naïve Bayes a partir de los datos históricos para calcular las probabilidades posteriores para cada clase: subscribed=yes and subscribed=no.

$$argmax_j \; p(y_j)\prod_{i=1}^{n} p(x_i|y_j)$$

| Marital | Subscribed=yes |
|---|---|
| Single | 35% |
| Married | 53% |
| Divorced | 12% |

| Marital | Subscribed=no |
|---|---|
| Single | 28% |
| Married | 61% |
| Divorced | 11% |

| | |
|---|---|
| Subscribed=yes | 11% |

| | |
|---|---|
| Subscribed=no | 88% |

¿Debería el banco ofrecerle un CDT al cliente con la información siguiente?

| | Subscribed=yes | Subscribed=no |
|---|---|---|
| Job=Management | 22% | 21% |
| Marital=Married | 53% | 61% |
| Education=Secondary | 46% | 51% |
| Default=no | 99% | 98% |
| Housing=yes | 35% | 57% |
| Loan=no | 90% | 85% |
| Contact=Cellular | 85% | 62% |
| Outcome=Success | 15% | 1% |
| Priors | 11% | 88% |

| | | |
|---|---|---|
| Numerador | 0.000234588 | 0.000169244 |
| Proba posterior | 58% | 42% |

# NAIVE BAYES (BAYES INGENUO)

Probabilidad Posterior

Probabilidad A priori

Verosimilitud

Regla de Bayes: $$p(y_j|x_1, x_2, \dots, x_n) = \frac{p(y_j, x_1, x_2, \dots, x_n)}{p(x_1, x_2, \dots, x_n)} = \frac{p(y_j) * p(x_1, x_2, \dots, x_n|y_j)}{p(x_1, x_2, \dots, x_n)}$$

evidencia

El denominador es solo usado para propósitos de normalización (suma de probabilidades = 1)

$$p(x_1, x_2, \dots, x_n) = \sum_j p(y_j) * p(x_1, x_2, \dots, x_n|y_j)$$

Solo nos interesa el numerador:

$$p(y_j, x_1, x_2, \dots, x_n) = p(y_j) * p(x_1|y_j) * p(x_2|x_1, y_j) * p(x_3|x_2, x_1, y_j) * \cdots * p(x_D|x_{1:D-1}, y_j)$$

Si asumimos ingenuamente (**naïvely**) que todas las variables predictivas $x_i$ son independientes condicionalmente con respecto a la clase $y_j$, entonces el numerador se simplifica:

$$p(y_j) * p(x_1|y_j) * p(x_2|y_j) * p(x_3|y_j) * \cdots * p(x_n|y_j)$$

$$= p(y_j) \prod_{i=1}^{n} p(x_i|y_j)$$

# NAÏVE BAYES (BAYES INGENUO)

La regla de clasificación es:

$$argmax_j \ p(y_j) \prod_{i=1}^{n} p\left(x_i \middle| y_j\right)$$

Sólo necesitamos especificar

→ Las probabilidades a priori de cada clase

→ Las distribuciones de probabilidad de las variables predictivas para cada clase (distribuciones de probabilidad condicionadas a la clase)

Esta información constituye los **parámetros** del modelo, y en el caso de variables categóricas se obtienen a partir de frecuencias (conteos)

# NAIVE BAYES: TALLER EXCEL

Taller de Excel de Naive Bayes.

Continuar con la parte 3, aplicando Bayes ingenuo para dos variables predictivas **categóricas**

# NAÏVE BAYES (BAYES INGENUO)

Es posible que con algunos de los valores de las variables predictivas tengan frecuencia nula con respecto a las categorías de la clase, por lo sus probabilidades asociadas serían cero.

Para evitar este problema, se utilizan métodos de **suavización**, que al contar las frecuencias de ocurrencia de cada valor, siempre se le agrega un valor pequeño $\varepsilon$, que impide que alguna probabilidad sea cero:

$$P(casado|cliente\ potencial) = \frac{Conteo(casado,\ cliente\ potencial) + \varepsilon}{Conteo(cliente\ potencial) + N(x) * \varepsilon}$$

El método de suavización de **Laplace** se aplica con $\varepsilon$=1

# NAÏVE BAYES (BAYES INGENUO)

Cuando las variables predictivas no son categóricas, es necesario establecer una distribución de probabilidad:

1. Se puede discretizar la variable convirtiéndola en categórica
2. Se puede establecer una distribución de probabilidad empírica utilizando KNN
3. Se puede suponer eventualmente que se trata de un tipo de distribución de probabilidad y utilizar su función de densidad.

Por ejemplo, si se supone que se trata de una variable que sigue una distribución normal condicionada a la categoría objetivo, se puede calcular la media μ y desviación estándar σ a partir de los datos históricos, y utilizar la función de densidad:

$$P(edad|cliente\ potencial) = \frac{1}{\sigma_{edad|cliente}\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{edad-\mu_{edad|cliente}}{\sigma_{edad|cliente}}\right)^2}$$

# NAÏVE BAYES (BAYES INGENUO)

Consideraciones

- Sólo se puede utilizar para **clasificación**
- Modelo **simple** y **eficiente**, que permite atributos tanto categóricos (2 o más) como numéricos,
- Sólo se necesita poder estimar **las probabilidades condicionales** con respecto a los valores de la categoría objetivo, pero se basa en **suposiciones** muy fuertes (aunque en la práctica obtiene resultados buenos en muchos contextos)
- Permite atributos con **valores faltantes**
- Ignora atributos **irrelevantes**
- **Muy sensible** a atributos correlacionados (considerar varias veces los mismos efectos)
- Resistente al **overfitting**, sobretodo si se incluye un suavizador (e.g. Laplace)
- Ideal cuando se tiene un gran número de dimensiones

# NAIVE BAYES: TALLER EXCEL

Taller de Excel de Naive Bayes.

Continuar con la parte 4, aplicando Bayes ingenuo con una combinación de variables **categóricas** y **numéricas**.

# NAIVE BAYES: IRIS

Taller de Python de Naive Bayes aplicado al dataset Iris.

# REFERENCIAS


- *Python Machine Learning (2nd ed.)*, Sebastian Raschka, Vahid Mirjalili, Packt Publishing, 2017
- *Real World Machine Learning*, Henrik Brink, Joseph W. Richards, Mark Fetherolf, 2017
- *Introduction to Statistical Learning with Applications in R (ISLR),* G. James, D. Witten, T. Hastie & R. Tibshirani, 2014